


Анализ землетрясений



Команда проекта

Маркова Мария, Мельникова Виктория, Яшин Артемий, Новиков Глеб

Цель и задачи

Цель проекта

Предсказать, будет ли землетрясение достаточно сильным — магниту́да $\geq 4,5$ (порог, после которого событие ощущается людьми и может причинить ущерб).

Основная гипотеза

Сильные события связаны с локальной сейсмической активностью и пространственным контекстом.

Задачи

01

EDA и baseline

Выполнить разведочный анализ данных и построить базовую модель

02

Аномалии и выбросы

Провести работу с аномалиями и выбросами в данных

03

Признаки

Обогатить датасет новыми признаками и отобрать самые значимые фичи

04

Интерпретация

Проинтерпретировать модели и провести их валидацию

Источник данных

Column	Type	Description
id	string	Unique event identifier
mag	float	Magnitude of the earthquake
place	string	Text description of location
time_utc	datetime	Event occurrence time (UTC)
longitude	float	Longitude of epicenter
latitude	float	Latitude of epicenter
depth_km	float	Depth in kilometers
url	string	Link to the USGS event detail page

Открытый датасет с Hugging Face
leorigasaki54/earthquake-events-180d (USGS Earthquake API)

Этот набор данных содержит записи о глобальных землетрясениях за последние **180 дней**, полученные из API-интерфейса USGS по землетрясениям. Он включает в себя магнитуду, местоположение (широту и долготу), время, глубину и URL-адрес для каждого события.

<https://huggingface.co/datasets/leorigasaki54/earthquake-events-180d>

USGS (аббревиатура от англ. United States Geological Survey) —
Геологическая служба США

EDA. Качество данных

Пропущенные значения		
	Пропуски	%
id	0	0.0
mag	0	0.0
place	0	0.0
time_utc	0	0.0
longitude	0	0.0
latitude	0	0.0
depth_km	0	0.0
url	0	0.0

Дублей по id: 0

**Данные хорошего качества,
нужна минимальная
предобработка**


Особенности сейсмических данных

- ❗ Отрицательная глубина: 771 событий (3.9%)
Отрицательная магнитуда: 1374 событий (6.9%)
Нулевая магнитуда: 28 событий (0.1%)


- Отрицательные значения глубины в данных USGS не означают «землетрясение над поверхностью». Обычно это связано с погрешностью определения очага для очень мелких событий. Для анализа такие значения были приведены к 0 км.
- Отрицательные и нулевые магнитуды являются физически корректными. Современные сейсмографы способны фиксировать крайне слабые события, недоступные старым приборам.

EDA. Дисбаланс классов

Распределение классов




Закон Гутенберга-Рихтера: $N(>=M)$ по магнитуде



- Сильные землетрясения составляют лишь около 5% выборки
- Dataset имеет выраженный дисбаланс (~19:1)
- Это критично для выбора метрик и настройки моделей. При обучении моделей потребуется использовать техники балансировки
- Правый график подтверждает закон Гутенберга-Рихтера: число землетрясений экспоненциально убывает с ростом магнитуды.

EDA. Зависимость магнитуды от глубины




- Большинство событий имеют низкую магнитуду
- Распределение имеет длинный «хвост»
- Сильные землетрясения являются редкими событиями





- Большинство событий — мелкофокусные (глубина 0–70 км)
- Глубокофокусные события (> 300 км) редки (1%).

EDA. Географическое распределение

Топ-12 регионов по числу событий



Топ-12 регионов по % сильных событий



- Основная концентрация наблюдается вдоль тектонических границ
- Наиболее активен регион Тихоокеанского огненного кольца
- Сейсмическая активность имеет выраженную пространственную локализацию.

Зона Вадати–Бениоффа

На региональных срезах обнаружены наклонные сейсмические пояса:

- Япония / Курилы — глубина увеличивается с востока на запад
- Чили / Перу — глубина растёт с запада на восток
- Алеуты / Аляска — глубина возрастает с юга на север




Главный вывод

Все три зоны подтверждают существование **наклонных сейсмических поясов** - признак субдукции океанической плиты под континентальную, а сильные события (≥ 4.5) концентрируются на глубинах до 150 км, где напряжения в плите максимальны.

Временной анализ

Данные не показывают значимой зависимости от часа суток или дня недели. Небольшие колебания доли сильных событий статистически незначимы. Это согласуется с сейсмологией: возникновение землетрясений не привязано ко времени суток.




b-value: региональный наклон закона Гутенберга–Рихтера

Идея

b-value характеризует соотношение числа слабых и сильных землетрясений в регионе

- $b < 0.9$ — зоны высоких напряжений и повышенной доли сильных событий
- $b \approx 1.0$ — типичная сейсмичность
- $b > 1.1$ — преобладание слабых событий



$$b = \frac{\log_{10}(e)}{\text{mean}(M) - M_c}$$

Где:

- M — магнитуда каждого отдельного события в выборке
- $\text{mean}(M)$ — среднее арифметическое значение магнитуд
- M_c — магнитуда полноты каталога (порог, начиная с которого зарегистрированы все землетрясения данного региона)

Выводы по b-value

Группа	Регионы	Интерпретация
$b < 0.9$ (красные)	Зоны субдукции и запертых разломов	Высокие напряжения -> повышенная доля сильных событий относительно слабых
$b = 1.0$ (оранжевые)	Типичные коровые разломы	Соответствует глобальной норме Гутенберга-Рихтера
$b > 1.1$ (зелёные)	Дисперсная/вулканическая сейсмичность	Меньше крупных событий относительно мелких

Ограничения оценки

- b-value чувствительно к выбору M_c : при заниженном M_c оценка b завышается
- При малом n (< 50) погрешность $\sigma_b > 0.1$ — результат нестабилен
- M_c варьируется по регионам: в удалённых районах USGS регистрирует только $\text{mag} > 3-4$

❏ **Для ML:** b-value как признак на уровне пространственной ячейки (не региона) потенциально полезен, но требует достаточной истории событий. На 180-дневных данных — ориентировочная надёжность.

Пространственно-временные признаки и форшоки

Сейсмический контекст

Идея: Землетрясения не независимы — после крупного толчка следуют афтершоки (закон Омори: частота убывает как $1/t$). Знание о прошлой активности в точке улучшает прогноз.

Форшоки: предшествующая активность

Вопрос: есть ли в данных предшествующая активность перед сильными ($M \geq 4.5$) событиями? Это проверяет, несёт ли `local_cnt_24h` реальный сигнал или просто шум.

1

`local_max_mag_24h`

Сильнейший предиктор: в активных афтершоковых сериях каждое последующее событие «видит» сильный предшественник → высокая вероятность ещё одного сильного. Корреляция отражает реальную сейсмологию (закон Омори)

2

`local_cnt_24h / local_cnt_7d`

Умеренная положительная корреляция: чем активнее ячейка в прошлом, тем выше вероятность сильного события

3



`global_cnt_24h`

Слабее локальных — глобальный фон маскирует региональный сигнал

4

`local_time_since_h`

Отрицательная корреляция: короткий интервал с прошлым событием характерен для активных серий. Для первого события в ячейке признак = NaN (30–40% строк) — при обучении обязательна импутация



0 форшоков

Большинство сильных событий имеют 0 форшоков — это подтверждает, что предсказание единичных «внезапных» событий остаётся крайне сложным

28% с предшественниками

Часть сильных событий (28%) имеют предшественников. Это вторичные толчки в афтершоковых сериях — они «видят» предыдущую активность

Нет связи с магнитудой

Нет выраженной связи числа форшоков с магнитудой. Более сильное событие не обязательно предворяется большим числом форшоков

Для прогноза важен не изолированный форшок, а **паттерн нарастающей активности**: рост `local_cnt_24h` и высокое `local_max_mag_24h` вместе — наиболее информативная комбинация.

Ключевые выводы EDA

1 Дисбаланс классов 19:1

Сильные землетрясения составляют лишь 5% событий. Это ключевая проблема при обучении.

3 Глубина слабо коррелирует с магнитудой

$r = 0.15$. Глубокофокусные события (> 300 км) в датасете редки (1%) — их статистика нестабильна, делать выводы об «опасности» некорректно.

5 Большинство сильных событий — без форшоков

Тем не менее совместный сигнал `local_cnt_24h` + `local_max_mag_24h` статистически значим и отражает афтершоковые серии.

7 Зона Вадати–Бениоффа

Видна на региональных срезах. Сильные события ($M \geq 4.5$) концентрируются на глубинах до 150 км, где напряжения в погружающейся плите максимальны.

2 Отрицательные значения

Отрицательные магнитуды — норма для современных сейсмографов, не удалять. Отрицательные глубины — артефакт алгоритма локации USGS («близко к поверхности»), клипировать до 0 при необходимости.

4 Большинство событий мелкофокусные

Глубина 0–70 км — 88% датасета. Глубина > 70 км — косвенный маркёр субдукционной обстановки.

6 Пространственно-временные признаки



`local_max_mag_24h`, `local_cnt_24h` — наиболее информативные предикторы; отражают закон Омори и кластеризацию афтершоков.

8 Временные признаки не несут ценности

Час UTC, день недели не показывают значимой зависимости — физически землетрясения не зависят от времени суток на Земле.

Baseline-модель

Модель	ROC-AUC	PR-AUC	F1	Precision	Recall	Accuracy
HistGradientBoosting	0.986300	0.836600	0.764000	0.634300	0.960500	0.973800
Random Forest	0.989800	0.775500	0.756300	0.686600	0.841800	0.976000
Logistic Regression	0.983700	0.672500	0.669200	0.508800	0.977400	0.957200
Dummy (most_frequent)	0.500000	0.044200	0.000000	0.000000	0.000000	0.955800
Dummy (stratified)	0.493000	0.043800	0.036000	0.033000	0.039500	0.906200



Генерация признаков и отбор переменных

Категориальные признаки

В данных есть категориальные признаки: `region` (высокая кардинальность) и `depth_cat` (4 значения).

Выбор кодирования:

- `depth_cat` - 4 значения, ONE подходит идеально.
- `region` - сотни значений. Label Encoding оставим как простой baseline, но в финальных моделях используем `region_te` - оно несёт информацию о "рискованности" региона и при этом устойчиво (за счёт сглаживания).
- Утечки нет: статистика `region_te` посчитана только по train, на test применяется уже зафиксированный словарь.

Признаки на основе ближайших соседей


У нас есть координаты, поэтому считаем kNN по координатам и собираем агрегаты по соседям. Используем BallTree с метрикой haversine - это правильное расстояние на сфере.

Гипотезы по признакам соседей:

- `knn_max_mag` - если рядом уже было сильное событие, повышается вероятность что и эта точка - сильная (афтершоковая серия).
- `knn_density` - в активных сейсмических зонах точки расположены плотнее, чем в пассивных. Высокая плотность = "горячая" зона.
- `knn_mean_dist_km` - обратное к density.

Распределения для слабых и сильных событий различаются - значит признаки несут полезный сигнал.

Временные признаки




Час, день недели и месяц - циклические величины. Для линейных моделей кодирование числами 0-23 создаёт ложную "большую" разницу между 23 и 0 (на самом деле они рядом). Поэтому используем $\sin/\cos$.

Точки лежат на окружности - именно то что нужно. По EDA мы уже знаем, что временные признаки имеют слабую связь с целью, но добавляем их корректно закодированными - вдруг в комбинации с другими признаками появится сигнал.

Отбор признаков

Применяем три подхода: фильтры (корреляции, ANOVA), обёртки (RFECV) и встроенные методы (L1, важности из бустинга).



Работа с аномалиями

Тип аномалии	Природа	Решение
Пропуски в основных колонках	Отсутствуют (датасет USGS чистый)	Ничего не делаем
Дубликаты	Отсутствуют (id уникален)	Ничего не делаем
Отрицательная глубина	Артефакт алгоритма гипоцентральной локации USGS - означает «приповерхностное» событие	Сохраняем как отдельную категорию Аномальная (< 0); в модели - <code>clip(lower=0)</code>
Магнитуда ≤ 0	Корректные физические значения (логарифмическая шкала)	Сохраняем
Сверхдальние глубины (>400 км)	Реальные глубокофокусные события из субдукционных зон	Сохраняем; это инсайт , а не выброс
Высокие магнитуды ($\text{mag} \geq 4.5$)	Это и есть таргет , по определению хвост распределения	Сохраняем - модель учится именно на них
Длинный хвост <code>local_cnt_24h</code> (рои/афтершоки)	Афтершоковые серии - закон Омори	Сохраняем; клиппинг <code>quantile(0.97)</code> только для визуализации
NaN в <code>local_max_mag_24h</code> , <code>local_time_since_h</code>	«Холодный старт» - первое событие в ячейке	Импутация (0 и 168 ч) в baseline

Работа с аномалиями

Статистические методы


- **Z-score** эффективно находит выбросы по магнитуде — но именно они часто соответствуют **сильным землетрясениям**, которые мы хотим предсказывать.
- **Z-score** также выделяет **реальные глубокофокусные события** (глубина 500+ км).
- **IQR** и **тест Граббса** помогают фиксировать формальные отклонения от распределения, но такие «аномалии» в данных по сейсмичности часто являются **сигналом, а не шумом**.

ML-методы

- Сравниваем **Isolation Forest** и **LOF** со статистическими подходами.
- Оцениваем качество по **Precision / Recall / F1 / ROC-AUC** относительно целевой переменной `is_strong`.
- Смотрим, **где методы совпадают**, а **где расходятся**, чтобы понять, какие точки действительно подозрительны.


Работа с аномалиями

хорошо ловит выбросы по магнитуде - это как раз сильные землетрясения, которые мы и пытаемся предсказывать. По глубине Z-score также находит реальные глубоководные события (500+ км). То есть формальные "выбросы" - на самом деле полезный сигнал




Работа с аномалиями. IQR (межквартильный размах)

более агрессивный метод - помечает как выбросы много точек. По магнитуде помечает всё что выше ~3.0, что включает почти все сильные землетрясения. Видно что IQR в нашей задаче не подходит для "очистки": слишком много полезного сигнала будет потеряно



Работа с аномалиями. ML-методы поиска выбросов

ML-методы: точки и их аномальный скор



Сравнение методов:

- IsolationForest даёт более стабильный ROC-AUC, потому что строит ансамбль деревьев и устойчив к шуму.
- LOF чувствителен к локальной плотности - хорошо ловит точечные аномалии, но даёт больше шума на больших данных.
- Оба метода частично совпадают с целевой переменной: сильные события действительно находятся в "редкой" области пространства признаков. Но ни один метод не заменяет supervised-классификатор, потому что они не используют метки.

Сохраняем флаги `iso_flag`, `lof_flag` и сами скоры как признаки для последующей модели.

Работа с аномалиями. Тест Граббса

Тест Граббса (проверяем самое экстремальное значение)

```
mag: G=4.46, G_crit=4.71, выброс: нет, значение=7.40
depth_km: G=12.11, G_crit=4.71, выброс: ДА, значение=667.24
latitude: G=5.18, G_crit=4.71, выброс: ДА, значение=-63.57
longitude: G=4.14, G_crit=4.71, выброс: нет, значение=180.00
```

Тест Граббса подтверждает: максимальные значения магнитуды и глубины статистически значимо отличаются от основной массы. Но это не повод их удалять - это редкие, но физически реальные события. Решение: оставляем как есть, но создадим бинарные флаги выбросов как признаки.

Выводы по этапу 2

- Статистические методы (Z-score, IQR, Граббс) подтвердили, что хвосты распределений магнитуды и глубины - это реальные физические события, а не шум. Удалять их нельзя.
- ML-методы (IsolationForest, LOF) дали ROC-AUC заметно выше случайного по отношению к целевой переменной - это значит сильные события действительно "выпадают" из основной массы по нескольким признакам одновременно. Это согласуется с supervised результатом.
- Новые признаки: соседи (kNN), флаги выбросов, target encoding регионов и циклическое кодирование - все они вошли в финальный отбор хотя бы по одному из методов.
- Финальный набор признаков получился компактнее исходного, но более информативным: HistGB на новом наборе даёт сопоставимый или лучший PR-AUC, чем на старом.
- Главное наблюдение из EDA подтверждается: пространственно-временные признаки доминируют, временные циклические признаки практически не вносят вклад.

	ROC-AUC	PR-AUC	F1	Recall	Precision
Модель					
LogReg (старый набор)	0.9837	0.6725	0.6692	0.9774	0.5088
LogReg (новый набор)	0.9926	0.8207	0.7692	0.9887	0.6295
HistGB (старый набор)	0.9863	0.8366	0.7640	0.9605	0.6343
HistGB (новый набор)	0.9924	0.8526	0.7791	0.9266	0.6721

Пересчёт baseline с расширенным набором признаков

Интерпретация и диагностика моделей

что-то про SHAP-эмбединги, сдвиги, валидацию и Shapley Flow

Интерпретация моделей: SHAP, LIME и SHAP-эмбеддинги

LogReg

HistGradientBoosting

Интерпретация и диагностика

To Do

- понять, какие признаки важны
- проверить согласованность моделей
- найти аномалии и структуру данных

1

Данные

2

HistGB / LogReg

3

SHAP/LIME

4


SHAP embeddings

5

Clustering

Интерпретация проводится для линейной и ансамблевой модели. Главная цель это понять структуру решений модели

Feature Importance: Random Forest



Основную роль играют признаки локальной и глобальной сейсмической активности. Это отражает физическую природу землетрясений — сильные события часто возникают внутри активных серий.

Главные предикторы — признаки сейсмического контекста. Календарные признаки почти не влияют

SHAP: глобальная важность признаков



Несмотря на различие архитектур, обе модели выделяют примерно одинаковые ключевые признаки. Это показывает, что найденный сигнал устойчив и не является артефактом конкретного алгоритма.

SHAP beeswarm: направление влияния признаков

Высокие значения топ-фич усиливают вероятность сильного события

SHAP показывает не только важность, но и направление влияния

Beeswarm-график позволяет увидеть, как именно признаки влияют на предсказание модели. Красные точки соответствуют большим значениям признаков, синие — маленьким. Видно, что высокие значения признаков локальной активности смещают предсказание в сторону сильных землетрясений.

Локальная интерпретация: одно конкретное событие

Для конкретного наблюдения вычисляются локальные SHAP-значения сразу для двух моделей. Обе модели выделяют схожие признаки, но HistGradientBoosting распределяет веса сложнее за счёт нелинейностей.

SHAP-эмбединги и поиск аномалий




Объекты с экстремально большими SHAP-значениями содержат значительно большую долю сильных землетрясений. Это означает, что модель действительно уверенно выделяет редкие и опасные события, а не реагирует на шум.

Кластеризация SHAP-эмбеддингов

После построения SHAP-эмбеддингов выполняется кластеризация несколькими алгоритмами. Полученные кластеры интерпретируются как разные режимы работы модели: типичные слабые события, активные серии, глубокофокусные землетрясения и другие группы.

SHAP interaction values: взаимодействия признаков



В ноутбуке вычисляются SHAP interaction values — оценки силы взаимодействия между признаками. Анализ показывает, что наиболее центральными признаками являются `local_max_mag_24h` и `global_max_mag_24h`. Географические и глубинные признаки образуют отдельную связанную группу.

Центральные узлы — `local_max_mag_24h` и `global_max_mag_24h`

Модель использует взаимодействия между признаками

Выводы этапа 3

Метод анализа	Описание
SHAP/LIME	Глобальная и локальная интерпретация
SHAP embeddings	Представление объектов через SHAP-вклады
Clustering	KMeans, Hierarchical, DBSCAN
Interaction graph	Взаимодействия между признаками
Cross-validation с SHAP	Проверка устойчивости

- SHAP подтверждает физическую осмысленность модели
- Топ-признаки совпадают между линейной и ансамблевой моделью
- SHAP-анализ показывает согласованную структуру влияний
- SHAP-эмбединги содержат дополнительную структуру данных
- Модель использует сложные комбинации признаков

Главный вывод этапа интерпретации заключается в том, что модель использует устойчивые и физически интерпретируемые закономерности. Дополнительно SHAP-эмбединги позволяют анализировать аномалии, кластеры и взаимодействия признаков. Это делает интерпретацию полноценным инструментом исследования структуры данных и поведения модели

Итоги

Задача прогнозирования интенсивных сейсмических событий ($M \geq 4.5$) характеризуется высокой степенью стохастичности, так как значительная часть мощных толчков происходит без явных прекурсоров. Тем не менее, достигнутые показатели PR-AUC, существенно превышающие базовую вероятность класса, подтверждают наличие в данных значимого предиктивного сигнала.

Интерпретация моделей методами SHAP и LIME продемонстрировала, что ключевую роль играют не статические параметры локации (координаты, глубина), а пространственно-временная динамика сейсмической активности. Это согласуется с фундаментальными физическими принципами: модель успешно выявляет паттерны кластеризации событий, опираясь на закономерности, близкие к закону Омори.

